

Sobre o conjunto de dados

Contexto

O phishing continua a ser uma das formas mais eficazes e bem-sucedidas para os cibercriminosos nos defraudarem e roubarem nossas informações pessoais e financeiras. Nossa crescente dependência da internet para realizar grande parte de nossas atividades diárias proporcionou aos fraudadores o ambiente perfeito para lançar ataques de phishing direcionados. Os ataques de phishing que ocorrem hoje são sofisticados e cada vez mais difíceis de detectar. Um estudo realizado pela Intel constatou que 97% dos especialistas em segurança não conseguem identificar e-mails de phishing em meio a e-mails legítimos.

Conteúdo

O conjunto de dados fornecido inclui 11.430 URLs com 87 características extraídas. Ele foi projetado para ser usado como referência para sistemas de detecção de phishing baseados em aprendizado de máquina. As características pertencem a três classes diferentes: 56 extraídas da estrutura e sintaxe das URLs, 24 extraídas do conteúdo das páginas correspondentes e 7 extraídas por meio de consultas a serviços externos. O conjunto de dados é balanceado, contendo exatamente 50% de URLs de phishing e 50% de URLs legítimas.

A coluna alvo para realizar as classificações é a coluna **status**, caracterizando se o site é legítimo ou um possível phishing.